

Rapport Data Scientist — Programme Néovolt Grid+

Cas d'usage traités : (1) détection de fraude sur les compteurs ; (2) prévision de la consommation réseau.

Livrables associés : scripts 06 → 10 , suspects_fraude.csv , prevision_test.csv , models/model_card.json .

1. Démarche expérimentale

La même rigueur a guidé les deux cas d'usage : **comprendre les données avant de modéliser, commencer par une baseline simple**, puis n'ajouter de la complexité que si elle apporte une valeur mesurable.

Détection de fraude. Les 3 types de fraude (sous-comptage, branchement illicite, compteur trafiqué) ont une signature commune : le compteur enregistre *moins* que la réalité. On a construit des features de comportement par compteur, dont la plus discriminante est le **ratio de chute** (consommation des 90 derniers jours / 90 premiers jours) : médiane 0,49 chez les fraudeurs contre 0,94 chez les clients sains. Trois approches ont été comparées : détection non supervisée (Isolation Forest), règle simple (tri par ratio de chute), et modèle supervisé (Random Forest).

Prévision de consommation. Série journalière de la demande totale, enrichie de variables calendaires, de **retards** (consommation de la veille et de la semaine précédente) et de la **météo** (température, degrés-jour). Validation strictement **chronologique** (entraînement sur le passé, test sur les 6 derniers mois).

2. Résultats et métriques

Le piège de l'exactitude. Avec 96,6 % de compteurs sains, un modèle qui prédit « tout le monde est honnête » atteint 96,6 % d'exactitude tout en détectant **zéro fraude**. C'est pourquoi l'évaluation repose sur des métriques adaptées au déséquilibre : précision, rappel, PR-AUC, et **recall@N** (part des fraudes connues retrouvées dans le top N des suspects).

Cas d'usage	Métrique clé	Résultat
-------------	--------------	----------

Détection de fraude	ROC-AUC	0,92
Détection de fraude	Recall@50 (top 50 suspects)	88 % des fraudes connues
Détection de fraude	Seuil recommandé 0,20	rappel 79 %, ~37 compteurs signalés
Prévision conso	MAPE à J+1	4,5 % (vs baseline saisonnière 6,1 %)

Deux enseignements méthodologiques forts. (1) En non supervisé, la **règle simple bat l'Isolation Forest** : le signal étant concentré dans une variable, le modèle complexe le dilue. (2) En supervisé, le **Random Forest dépasse la règle simple** (88 % vs 67 % au top 50) en combinant le ratio de chute *et* la consommation relative aux pairs — il rattrape ainsi les fraudes « sans chute » (frauduleuses dès le départ). La complexité n'est utile que lorsqu'elle est *guidée* par le signal.

3. Évaluation critique : limites et biais

Limites des données. Seulement **24 fraudes confirmées** : c'est très peu pour un apprentissage robuste, et les métriques ont une forte incertitude. Surtout, le groupe « normal » contient **presque certainement des fraudes non encore détectées** (l'énoncé le dit) : nos étiquettes sont donc *bruitées*, ce qui sous-estime la vraie performance (des « faux positifs » du modèle pourraient être de vraies fraudes ignorées). La représentativité de l'échantillon de 700 compteurs vis-à-vis des 600 000 réels est une hypothèse.

Limites des modèles. Le ratio de chute ne détecte pas une fraude présente *dès l'origine* (rien ne « baisse »). La prévision à 4,5 % se dégrade lors d'événements rares non vus à l'entraînement (vague de froid exceptionnelle, jour férié atypique).

Biais et risques éthiques. Le risque majeur est le **faux positif** : accuser à tort un client honnête. Conséquences possibles — atteinte à la réputation, discrimination involontaire si le modèle signale plus certaines zones ou certains profils. Parades : (1) le modèle ne **décide jamais seul** — il produit une liste de suspects soumise à **revue humaine obligatoire** (exigence RGPD sur les décisions automatisées) ; (2) un **contrôle d'équité** par type de client et par zone doit précéder tout déploiement ; (3) une **AIPD** (analyse d'impact RGPD) est requise pour ce traitement.

4. MLOps : industrialisation

Versioning. Modèles sauvegardés avec version + horodatage ; code sous Git ; données de référence figées. **Suivi d'expériences.** Métriques journalisées dans une *model card*

(`model_card.json`) — en production, un outil comme MLflow. **Reproductibilité.** Graine aléatoire fixée, dépendances épinglées, pipeline de features sauvegardé avec le modèle.

Déploiement. Fraude : **scoring batch quotidien** (J+1), liste de suspects transmise à l'équipe anti-fraude via l'API (volet Ingénierie). Prévission : **exécution quotidienne** alimentant la décision d'achat d'énergie. **Surveillance.** Détection de **dérive des données** (la distribution des consommations change-t-elle ?) et de **dérive du modèle** (le rappel baisse-t-il ?) ; ré-entraînement déclenché si la performance franchit un seuil d'alerte ; supervision des volumes de suspects signalés.

5. Ouverture (perspective)

Une brique d'**IA générative** pourrait traduire le score d'un compteur suspect en **explication lisible** pour l'agent (« consommation divisée par deux en septembre, 40 % sous les clients similaires »), accélérant la revue humaine sans jamais se substituer à elle. C'est une piste d'amélioration, à encadrer pour éviter toute sur-confiance dans l'explication générée.